CIFAR10 图像分类实验报告

姓名：龚晓博　学号：10245501469　2026-11-12

https://github.com/ding89852/contemporary-artificial-intelligence/tree/project3

摘要

本实验在 CIFAR10 上比较轻量 CNN 与 ImageNet 预训练 ResNet18。最终模型将 ResNet18 首层改为 3×3、步长 1 卷积并移除首层池化，在 10,000 张测试图上取得 94.49% 准确率和 0.9448 宏平均 F1，较 CNN 基线提高 10.29 个百分点。实验进一步利用混淆矩阵、误分类样本和 GradCAM 分析误差来源与模型关注区域。

1 实验任务与数据

任务为 CIFAR10 十分类。原始 50,000 张训练图按固定种子划为 45,000 张训练集和 5,000 张验证集，10,000 张官方测试图仅在最终评估时使用。训练阶段采用随机裁剪和水平翻转，评估阶段仅执行 ToTensor 与按通道标准化（均值为 0.4914、0.4822、0.4465，标准差为 0.2470、0.2435、0.2616）。

表 1　数据划分

集合	数量	用途
训练集	45,000	参数更新与数据增强
验证集	5,000	最佳权重选择与收敛监测
测试集	10,000	最终泛化性能评估

2 模型设计与训练方法

轻量 CNN 基线由三个双卷积模块组成，每块包含两层 3×3 卷积、BatchNorm、ReLU 和最大池化，通道数为 32、64、128，最后经全局平均池化、Dropout 和全连接层输出 10 类，参数量为 288,746。ResNet18 利用残差连接和 ImageNet 预训练特征；标准首层会过早降低空间分辨率，因此最终版本改用 3×3、步长 1 卷积并移除首层池化，使 32×32 输入保留更多细节。

所有模型使用带 0.1 标签平滑的交叉熵损失和 AdamW 优化器。训练采用 CUDA 混合精度、梯度裁剪、余弦退火和早停。学习率为 3×10^{-4}，权重衰减为 5×10^{-4}，批量大小为 128，随机种子为 42，实验设备为 RTX 4070 Laptop GPU。

3 模型对比与训练过程

三个模型在同一测试集上评估。最终模型的 94.49% 准确率比轻量 CNN 高 10.29 个百分点，比保留 ImageNet 输入结构的 ResNet18 高 8.73 个百分点，说明预训练特征与 CIFAR 输入分辨率适配共同改善了性能。

表 2　模型性能对比

模型	测试准确率	宏 F1	最佳验证准确率	参数量
Simple CNN	84.20%	0.8414	83.32%	288,746
ResNet18 ImageNet stem	85.76%	0.8571	85.48%	11,181,642
ResNet18 CIFAR stem	94.49%	0.9448	94.90%	11,173,962

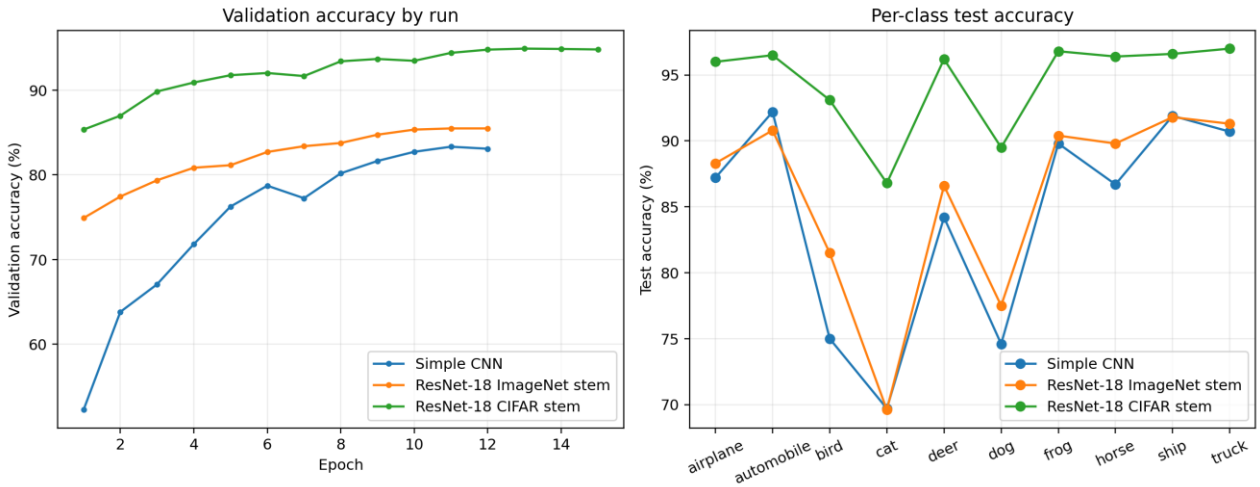


图 1　三种模型的验证准确率与测试集分类表现

最终模型在前 3 个 epoch 从 85.34% 提升到 89.84%，第 13 个 epoch 达到最佳验证准确率 94.90%。余弦退火后模型进入稳定收敛区域，验证准确率最后保持在约 94.8%。

4 测试集结果

最终模型正确分类 9449 张图像，准确率 94.49%，宏精确率、宏召回率和宏 F1 分别为 0.9448、0.9449 和 0.9448。训练准确率最终为 99.71%，验证准确率为 94.90%，存在一定过拟合但仍保持较好的测试泛化。

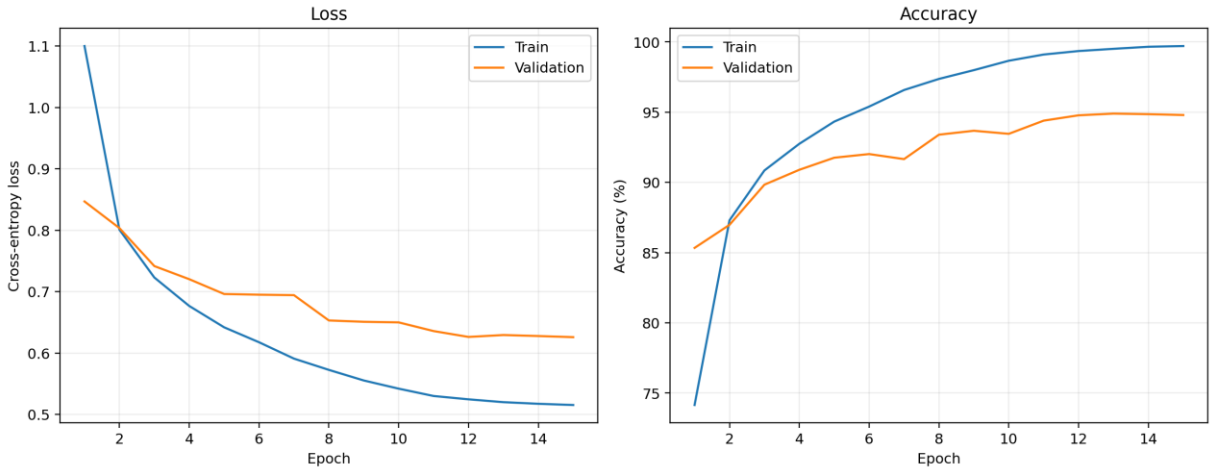


图 2　最终模型的训练与验证损失、准确率曲线

4.1 各类别分类指标

表 3　各类别测试指标

类别	精确率	召回率	F1
飞机 (airplane)	94.86%	96.00%	0.9543
汽车 (automobile)	97.57%	96.50%	0.9703
鸟 (bird)	95.19%	93.10%	0.9414
猫 (cat)	87.41%	86.80%	0.8710
鹿 (deer)	94.50%	96.20%	0.9534
狗 (dog)	90.96%	89.50%	0.9022
蛙 (frog)	96.99%	96.80%	0.9690
马 (horse)	96.69%	96.40%	0.9654
船 (ship)	96.31%	96.60%	0.9646
卡车 (truck)	94.36%	97.00%	0.9566

猫和狗的召回率最低，分别为 86.80% 和 89.50%；鸟为 93.10%。其余类别均超过 96%，车辆类别的表现尤其稳定。

4.2 混淆矩阵

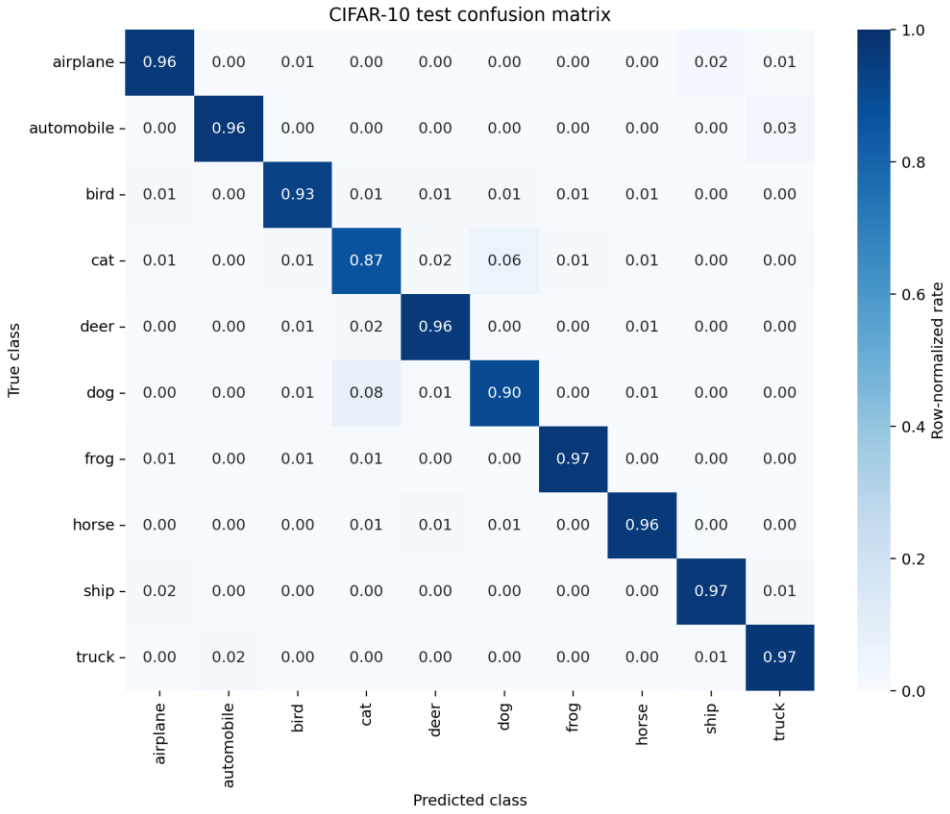


图 3　测试集行归一化混淆矩阵

主要误差为狗误判为猫 77 张、猫误判为狗 61 张、汽车误判为卡车 30 张、飞机误判为船 20 张、猫误判为鹿 18 张、卡车误判为汽车 17 张。猫与狗具有相似的毛发纹理和四足动物轮廓；飞机与船、汽车与卡车则容易受到背景、视角和整体形状影响。

5 误分类样本分析

图 4 为置信度最高的 8 个错误样本。部分狗的主体较小、姿态侧向或毛发颜色接近猫；交通工具错误通常伴随远距离视角、背景干扰或局部轮廓不完整。正确样本平均置信度为 0.8895，错误样本为 0.6406，但仍有超过 0.93 的高置信度错误，因此不能仅依赖阈值过滤。

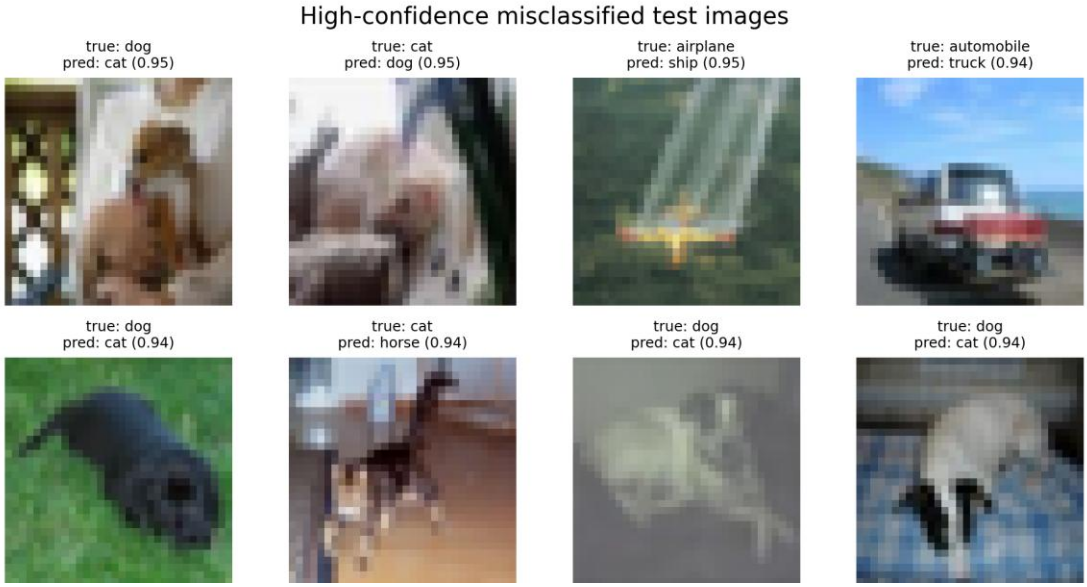


图 4　部分高置信度误分类样本

6 GradCAM 可解释性分析

GradCAM 使用最后一个残差阶段的梯度和激活图估计关键区域。正确分类时，高响应区域主要覆盖目标主体；错误分类时，热点仍位于物体附近，但模型关注的结构更接近被误判类别。例如汽车被识别为卡车时，响应集中在车体比例和上部轮廓。

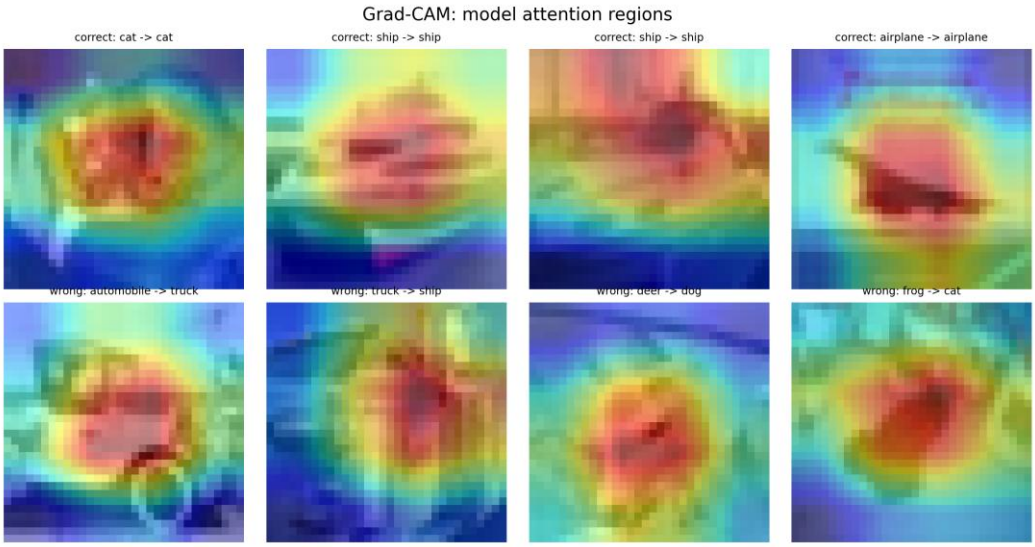


图 5　正确与错误样本的 GradCAM 注意力区域

7 讨论与改进方向

CIFAR 输入层适配是本实验最明显的结构改进。保留标准 ImageNet 首层时，32×32 图像会被 7×7 大步长卷积和池化快速压缩；改为 3×3、步长 1 后，后续残差阶段能够利用更多空间细节。需要注意，两次 ResNet 实验同时改变了输入结构和增强策略，因此该差距不能全部归因于首层结构，后续应按单变量方式做消融实验。

当前训练准确率接近 99.71%，验证准确率约 94.9%，仍有过拟合风险。后续可使用 MixUp、CutMix、随机深度或冻结浅层参数控制模型容量，也可通过测试时增强、模型集成和多次随机种子实验提高结果稳定性。针对猫、狗和鸟，可增加遮挡、姿态、尺度和复杂背景样本。

8 结论

实验完成了数据划分、模型设计、迁移学习训练、测试评估、误差分析与可解释性分析的完整流程。轻量 CNN 以约 29 万参数取得 84.20% 测试准确率，适合作为效率基线；适配 CIFAR 输入分辨率的 ResNet18 达到 94.49% 准确率和 0.9448 宏 F1，是本实验性能最高的模型。

误差主要集中在猫与狗、飞机与船、汽车与卡车等视觉相似类别。预训练特征只有在输入结构合理时才能充分发挥作用，后续应通过单变量消融和重复实验验证结构改动，并针对易混类别继续改进。

复现说明

代码位于 project3：train.py 负责训练，evaluate.py 负责评估与可视化，compare.py 负责模型对比。运行命令、依赖和文件说明见 README.md；最佳权重为 results/resnet18_cifarstem_basic/best.pt。